

GUÍA TÉCNICA · FASE 2

El Cerebro del SAT

IA + Machine Learning en Google Earth Engine para Sistemas de
Alerta Temprana de Inundaciones



Qué vamos a recorrer

01

Fundamentos de GEE

Qué es Earth Engine y por qué se usa para monitoreo ambiental

02

Construir la cuenca

Delimitar el área de estudio y cargar el terreno (DEM)

03

Variables predictoras

Pendiente y lluvia acumulada: los datos que alimentan al modelo

04

El modelo de IA

Random Forest: cómo la máquina aprende a detectar peligro

05

Evaluar y visualizar

Matriz de confusión y mapa final de riesgo

06

De prototipo a SAT

Qué falta para operar este modelo en el mundo real

¿Qué es Google Earth Engine?

Piénsalo como un catálogo gigante de imágenes satelitales del planeta, conectado a una supercomputadora en la nube que hace los cálculos por ti — sin descargar nada a tu computadora.



Catálogo de datos

Décadas de imágenes satelitales, modelos de elevación (DEM) y clima, ya listos para usar.



Procesamiento en la nube

Los cálculos pesados (como clasificar millones de píxeles) corren en los servidores de Google, no en tu PC.



Python / JavaScript

Se controla con código: en este curso usamos la librería ``ee`` de Python junto con ``geemap`` para visualizar mapas.

¿Qué estamos tratando de resolver?

Queremos construir un mapa de peligro de inundación: para cada punto de una cuenca hidrográfica, predecir qué tan probable es que sea una zona de riesgo — combinando el terreno, la lluvia y un modelo de inteligencia artificial.



Este flujo se llama, en Machine Learning, un pipeline: una cadena de pasos que transforma datos crudos en una predicción útil.

Delimitar el área de estudio


El truco del “**anzuelo espacial**”: en vez de dibujar a mano el contorno de una cuenca hidrográfica, colocamos un solo punto de coordenadas dentro de ella.

Ese punto se usa para “**pescar**” **automáticamente** el polígono exacto desde **HydroBASINS**, una base de datos mundial de cuencas ya delimitadas por hidrólogos.

En código (ee = Earth Engine):

```
punto = ee.Geometry.Point([-90.52, 14.6])
```

```
cuenca =  
ee.FeatureCollection('HydroBASINS').filterBounds(punto).first()
```



El modelo de elevación (DEM)

Un DEM (Digital Elevation Model) es, en esencia, una imagen donde cada píxel guarda la altura del terreno en metros. Usamos SRTM, un DEM global gratuito disponible directamente en GEE, y lo recortamos exactamente a la forma de nuestra cuenca.



USGS/SRTMGL1_003

El dataset de elevación global (resolución ~30m) que traemos de la nube de GEE.



.clip(cuenca)

Recortamos el DEM mundial para quedarnos solo con el pedazo dentro de nuestra cuenca.



Slope (pendiente)

A partir del DEM calculamos la inclinación del terreno — clave para saber por dónde escurre el agua.

Las variables predictoras

Un modelo de IA aprende a partir de “pistas” numéricas llamadas predictores o features. Aquí usamos dos:



Pendiente (Slope)

Se calcula con `ee.Terrain.slope(dem)`. Terrenos planos y bajos cerca de ríos acumulan más agua → mayor riesgo.



Lluvia acumulada (CHIRPS)

Suma de precipitación de todo 2023, desde el dataset satelital CHIRPS. Más lluvia acumulada → más riesgo de inundación.



Feature Stack (pila de predictores)

`ee.Image.cat([pendiente, lluvia])` apila ambas capas en una sola imagen multibanda: cada píxel ahora trae consigo “pendiente” y “lluvia” juntas — listo para alimentar al modelo.

¿Cómo aprende el modelo? Las etiquetas

Un modelo “supervisado” necesita ejemplos ya resueltos para aprender: puntos donde YA sabemos si hubo peligro (1) o no (0). A esa respuesta correcta se le llama etiqueta o label.



Importante — en este ejercicio la etiqueta es sintética: se define con una regla simple (lluvia > 1500 mm = “peligro”), no con inundaciones reales observadas. Es un atajo didáctico para aprender el flujo completo.

dataset_muestras — 1000 puntos aleatorios dentro de la cuenca:

Punto	Slope	Rainfall	label
#001	4.2°	1180 mm	0
#002	12.8°	1620 mm	1
#003	2.1°	1740 mm	1
#004	7.5°	980 mm	0


Real vs. simulado:

Las coordenadas, la pendiente y la lluvia son datos reales de satélite. Solo el label (0/1) es una simulación creada para practicar.

Random Forest: el “cerebro” del modelo

Random Forest (“bosque aleatorio”) es un algoritmo de Machine Learning que combina muchos árboles de decisión simples. Cada árbol “vota” si un punto es peligroso o no, y la mayoría gana.

100 árboles de decisión (*smileRandomForest*)



Consenso
Voto Mayoritario
= 1 (Peligro)

¿Por qué “bosque” y no un solo árbol?

Cada árbol ve una muestra distinta de datos. Al promediar sus votos, el error de un árbol individual se compensa — el modelo generaliza mejor y es menos sensible al ruido.

Entrenar y guardar datos para probar

Nunca evaluamos un modelo con los mismos datos que usó para aprender — sería como calificar un examen con las respuestas que el estudiante ya memorizó. Por eso dividimos el dataset:

80% · Entrenamiento

El modelo estudia con el 80%

Ve pendiente, lluvia y el label real, y ajusta sus árboles de decisión para aprender los patrones.

20% · Validación

Se examina con el 20% restante

Datos que el modelo nunca vio — así comprobamos científicamente si realmente aprendió, o solo memorizó.

¿Qué tan bien predijo el modelo?

La matriz de confusión compara lo que el modelo predijo contra la realidad, para cada clase.

La diagonal (verde) representa los aciertos del sistema.

		PREDICCIÓN →	
		No peligro	Peligro
REALIDAD ↓	No peligro	63 Aciertos	0
	Peligro	0	145 Aciertos

PRECISIÓN GENERAL

100%

(Overall Accuracy = 1.0)

⚠ ¡Alerta de Sobreajuste!

Un valor tan perfecto suele indicar sobreajuste (overfitting) o que las etiquetas sintéticas son "muy fáciles" de aprender — no significa que el modelo esté listo para producción.

- Meta operativa para un SAT real: precisión > 85%.

El mapa final de índice de peligro

El modelo entrenado se aplica a cada píxel de la cuenca (.classify()), generando un mapa continuo que combina el relieve (hillshade) con la predicción de riesgo.



Límite de la cuenca (vectorial)

-  Bajo peligro
-  Peligro medio
-  Alto peligro

Capas superpuestas en geemap:

- Hillshade (relieve)
- Índice de peligro (IA)
- Límite vectorial de la cuenca

De prototipo educativo a SAT operativo

Este notebook es una base excelente para aprender el flujo completo. Para convertirlo en una herramienta real de alerta temprana, hace falta:



01

Datos reales de inundación

Reemplazar la etiqueta sintética por registros históricos verificados: huellas de inundación satelitales (Sentinel-1), estaciones de caudal, reportes de campo.



02

Más predictores

Incorporar el Índice de Humedad Topográfica (TWI) y embeddings satelitales (AlphaEarth) que en esta versión didáctica se dejaron fuera.



03

Validación robusta

Una precisión del 100% en datos sintéticos es sospechosa — se necesita validación cruzada con datos reales y variados.



04

Automatización y monitoreo

Ejecutar el modelo de forma recurrente (ej. tras cada evento de lluvia fuerte) y conectar las alertas a un sistema de notificación.

Términos clave, en una frase

GEE

Plataforma en la nube de Google con datos satelitales y poder de cómputo listos para usar.

DEM

Imagen donde cada píxel representa la altura del terreno.

Feature / Predictor

Una variable numérica (ej. pendiente, lluvia) que el modelo usa para predecir.

Label / Etiqueta

La respuesta correcta que le enseñamos al modelo durante el entrenamiento.

Random Forest

Un algoritmo que combina muchos árboles de decisión y promedia sus votos.

Matriz de confusión

Tabla que compara predicciones del modelo contra la realidad.